	return(gsub("_", ".", column)) } names(reworked.df) <- sapply(names(reworked.df), column.notation) #Menjamo"HDI" u malo "hdi" names(reworked.df) <- sapply(names(reworked.df), tolower) #gdp.for.year iz string u numeric reworked.df\$gdp.for.year <- sapply(reworked.df\$gdp.for.year, function(x) {gsub(",", "", x)}) reworked.df\$gdp.for.year <- sapply(reworked.df\$gdp.for.year, as.numeric) #Potrebno napraviti faktore reworked.df\$sex <- as.factor(reworked.df\$sex) reworked.df\$seq <- factor(reworked.df\$sex, level=c("5.14 years" "15.24 years" "15.24 years" "15.24 years" "15.54
	"5-14 years", "15-24 years", "25-34 years", "35-54 years", "55-74 years", "75+ years"), ordered = TRUE) #unique(reworked.df\$generation) reworked.df\$generation <- factor(reworked.df\$generation, level=c("G.I. Generation", "Silent", "Boomers", "Generation X", "Millenials", "Generation Z")) head(reworked.df) A data.frame: 6 × 12 country year sex age suicides.no population suicides.100k.pop country.year hdi.for.year gdp.for.year gdp.per.capita generation
[3]:	3 Albania 1987 female 15-24 years 14 289700 4.83 Albania1987 NA 2156624900 796 Generation X 4 Albania 1987 male 75+ years 1 21800 4.59 Albania1987 NA 2156624900 796 G.I. Generation 5 Albania 1987 male 25-34 years 9 274300 3.28 Albania1987 NA 2156624900 796 Boomers 6 Albania 1987 female 75+ years 1 35600 2.81 Albania1987 NA 2156624900 796 G.I. Generation apply(reworked.df, 2, function(x) sum(is.na(x))) country: 0 year: 0 sex: 0 age: 0 suicides.no: 0 population: 0 suicides.100k.pop: 0 country.year: 0 hdi.for.year: 19456 gdp.for.year: 0 gdp.per.capita: 0 generation: 0 #Proverimo da li su za svaku državu obezbeđeni podaci za iste godine country.year <- aggregate(reworked.df["year"], list(country = reworked.df\$country), unique)
	A data.frame: 6 × 2 Country Cou
2	merenja tek od 1987. Takođe postoji ponavljanje podataka kao što su hdi.for.year, gdp.for.year i gdp.per.capita koji se ponavljaju čak 12 puta (6 starosnih grupa za muški pol i 6 starosnih grupa za ženski pol za datu godinu). *Varijabla suicides.100k.pop predstavlja količnik varijabli suicides.no i population Istraživačka pitanja: 1. Koje države imaju najveću stopu samoubistava? 2. Koje starosne grupe su nasklonije suicidu? 3. Da li postoji značajno veća stopa kod odrećenog pola? 4. Da li je u nekoj generaciji suicid zastupljeniji? 5. Od čega zavisi ta stopa?
[5]: [[6]: [1. Koje države imaju najveću stopu suicida Za odgovor na ovo pitanje koristiću godinu sa najviše opservacija. Razlog je taj što nemaju sve države podatke za sve godine. Ukoliko bi ovo ignorisali, dobili bi takve podatke da su neke vi pozicionirane samo zbog toga što imaju više opservacija (godina). Zbog toga smatram da se ovo pitanje, kao i nekoliko sledećih, treba vezati za određenu godinu. which.max(table(reworked.df\$year)) 2009: 25 year2009 <- as.data.frame(reworked.df[reworked.df\$year == 2009,]) year2009.suicides.agg <- aggregate(year2009[c("suicides.no", "population")], list(country = year2009\$country), sum)
	year 2009 . suicides . agg\$suicides . 100k . pop <- year 2009 . suicides . agg\$population year 2009 . suicides . agg <- year 2009 . suicides . agg [
[7]:	67 Russian Federation 37408 134085433 0.0002789863 77 Suriname 131 470448 0.0002784580 44 Kazakhstan 3838 14370635 0.0002670724 1. Koje starosne grupe su sklonije suicidu? Računaće se za sve države. Za razliku od prošlog primera neću računati nove vrednosti suicides.100k.pop, već ću sabrati postojeće. Takva sumirana vrednost nije ista kao i ona koja se dol kao suicides.no / population ali smatram da oslikava istu pojavu. year 2009. age. agg <- aggregate (year 2009["suicides.100k.pop"], list(age=year 2009\$age), sum) #install.packages("RColorBrewer") library(ggplot2) library(RColorBrewer) ggplot(year 2009. age. agg, aes (x=age, y=suicides.100k.pop, fill=age)) + geom_bar(stat="identity", color="black") + labs(x="starosne grupe", y="Sumirana stopa suicida") + scale_fill_brewer(palette="Blues")
	1. Koji pol je skloniji suicidu? year2009.sex.agg , aes(x=sex, y=suicides.100k.pop, fill=sex)) + geom_bar(stat="identity", color="black") +
	labs(x="Pol", y="Sumirana stopa suicida") + scale_fill_brewer(palette="Blues")
[9]:	sex.age.agg <- aggregate(year2009["suicides.100k.pop"], list(sex = year2009\$sex, age = year2009\$age), sum) ggplot(sex.age.agg, aes(x = age, y = suicides.100k.pop, fill = sex)) + geom_bar(stat="identity", color="black", position = "dodge") +
	scale_fill_brewer(palette="Paired") + labs(x = "Starosne grupe", y= "Summirana stopa suicida", title="Stopa suicida po starosnim grupama i polu") Stopa suicida po starosnim grupama i polu 2000- 20
L0]:	1. U kojoj generaciji je suicid zastupljeniji? generation <- aggregate(year2009["suicides.100k.pop"], list(generation=year2009\$generation), sum) generation
	A data.frame: 5 × 2 generation suicides.100k.pop <fct> < dbb Silent 6177.07 Boomers 2506.18 Generation X 1957.17 Millenials 1429.18 Generation Z 106.44 1. Od čega zavisi stopa suicida? Za odgovor na ovo pitanje moram koristiti i vairjablu sa HDI vrednostim. Početna hipoteza je da stopa zavisi od HDI-ja i GDP-ja. Koristiće se godina sa najveć</fct>
L1]: 	brojem HDI opservacija. hdi.df <- as.data.frame(reworked.df[is.na(reworked.df\$hdi.for.year) == FALSE,]) which.max(table(hdi.df\$year)) 2010: 6 year2010 <- as.data.frame(hdi.df[hdi.df\$year == 2010,]) head(year2010) A data.frame: 6 × 12 country year sex age suicides.no population suicides.100k.pop country.year hdi.for.year gdp.for.year gdp.per.capita generation <chr <in=""></chr>
13]:	253 Albania 2010 male 55-74 years 20 241852 8.27 Albania2010 0.722 11926953259 4359 Silent 254 Albania 2010 male 35-54 years 20 371611 5.38 Albania2010 0.722 11926953259 4359 Generation X 255 Albania 2010 male 25-34 years 9 179720 5.01 Albania2010 0.722 11926953259 4359 Generation X 256 Albania 2010 male 75+ years 2 50767 3.94 Albania2010 0.722 11926953259 4359 Silent 257 Albania 2010 male 15-24 years 10 279508 3.58 Albania2010 0.722 11926953259 4359 Millenials 258 Albania 2010 female 25-34 years 6 183579 3.27 Albania2010 0.722 11926953259 4359 Generation X 259 Albania 2010 agg <- aggregate(year2010.agg <- aggregate(year2010[, c("suicides.no", "population")], list(country = year2010\$country), unique) 250 year2010.agg <- aggregate(year2010[, c("suicides.no", "population")], list(country = year2010\$country), sum) 250 year2010.agg ("suicides.no", "population") c. year2010.agg
	head(year2010.agg) Paris Population*, "suicides.100k.pop") Population*, "suicides.100k.pop" Population*, "suicid
	shapiro.test(year2010.agg\$suicides.100k.pop) shapiro.test(year2010.agg, aes(hdi.for.year) ggplot(year2010.agg, aes(hdi.for.year, suicides.100k.pop)) + geom_point() cor.test(year2010.agg\$hdi.for.year, year2010.agg\$suicides.100k.pop, method="spearman") Shapiro-Wilk normality test data: year2010.agg\$suicides.100k.pop W = 0.93155, p-value = 0.0002438
	Warning message in cor.test.default(year2010.agg\$hdi.for.year, year2010.agg\$suicides.100k.pop, : "Cannot compute exact p-value with ties"
	06 20-04- 1e-04- 0e+00- 06 07 08 03 03 hdi.for.year
15]:	Varijabla suicides.100k.pop nije normalno raspoređena. Varijabla hdi.for.year nije normalno raspoređena. Korelacija između ove dve varijable statistički značajna ali je slaba. shapiro.test(year2010.agg\$gdp.per.capita) cor.test(year2010.agg\$gdp.per.capita, year2010.agg\$suicides.100k.pop, method="spearman") ggplot(year2010.agg, aes(gdp.per.capita, suicides.100k.pop)) + geom_point() Shapiro-Wilk normality test data: year2010.agg\$gdp.per.capita W = 0.83498, p-value = 2.966e-08 Spearman's rank correlation rho data: year2010.agg\$gdp.per.capita and year2010.agg\$suicides.100k.pop S = 74408, p-value = 0.02394 alternative hypothesis: true rho is not equal to 0 sample estimates:
	7 ho 0, 2466538
	Korelacija između ove dve varijable ne postoji ili nije značajna. Sada će se pristupiti modelovanju ovih podataka da eventualno predviđanje. Koristiće se decision tree analiza. #install.packages(c("rpart", "rpart.plot")) library(rpart) library(rpart.plot) train.data <- as.data.frame(year2010.agg) third.q <- quantile(train.data\$suicides.100k.pop, 0.75) train.data\$high.rate <- ifelse(train.data\$suicides.100k.pop > third.q, "Yes", "No") train.data\$high.rate <- as.factor(train.data\$high.rate) train.data[c("country", "suicides.100k.pop")] <- NULL
	head(train.data) Modifor.year M
	tree1 <- rpart(high.rate ~. , train.data, method = "class") print(tree1) rpart.plot(tree1) n= 84 node), split, n, loss, yval, (yprob) * denotes terminal node 1) root 84 21 No (0.75000000 0.25000000) 2) suicides.nov124 22 1 No (0.95454545 0.04545455) * 3) suicides.nov124 22 1 No (0.67741935 0.32258065) 6) population>=3200861 54 13 No (0.75925926 0.24074074) 12) suicides.nov 703.5 17 0 No (1.00000000 0.00000000) 13) suicides.nov=703.5 37 13 No (0.64864865 0.35135135) 26) population>=3200861 84 1 No (0.94444444 0.055555565) * 53) Suicides.nov=5607.5 18 1 No (0.94444444 0.055555565) * 53) Suicides.nov=5607.5 7 3 Yes (0.42857143 0.57142857) * 27) population< 1.046851e+07 12 4 Yes (0.33333333 0.66666667) * 7) population< 3200861 8 1 Yes (0.12500000 0.87500000) *
I	euicides.no < 704 No
.8]:	train.data2 <- as.data.frame(year2010) q3 <- quantile(train.data2\$suicides.100k.pop, 0.75) train.data2\$high.rate <- ifelse(train.data2\$suicides.100k.pop > q3, "Yes", "No") train.data2\$high.rate <- as.factor(train.data2\$high.rate) train.data2[c("country", "year", "suicides.100k.pop", "country.year")] <- NULL head(train.data2) A data.frame: 6 × 9
	255 male 25-34 years 9 179720 0.722 11926953259 4359 Generation X No 256 male 75+ years 2 50767 0.722 11926953259 4359 Silent No 257 male 15-24 years 10 279508 0.722 11926953259 4359 Millenials No 258 female 25-34 years 6 183579 0.722 11926953259 4359 Generation X No tree2 <- rpart(high.rate ~. , train.data2, method = "class") print(tree2) rpart.plot(tree2) rpart.plot(tree2) rpart.plot(tree2) node), split, n, loss, yval, (yprob) * denotes terminal node
	1) root 1808 252 No (0.758080000 0.258080000) 2) sex=memale 504 26 No (0.94841270 0.05158730) * 3) sex=memale 504 226 No (0.55158730 0.44841270) 6) suicides.no< 58.5 272 61 No (0.77573529 0.22426471) 12) population=190637.5 124 4 No (0.96774194 0.03225806) * 13) population< 190637.5 148 57 No (0.61486486 0.38513514) 26) suicides.no< 3.5 79 7 No (0.91139241 0.08860759) * 27) suicides.no< 1.5 41 19 Yes (0.42541463 0.53658537) 188) population=45716 24 5 No (0.79166667 0.20833333) * 189) population=45716 24 5 No (0.79166667 0.20833333) * 199) population=45716 17 0 Yes (0.080000000 1.080000000) * 55) suicides.no>=17.5 28 0 Yes (0.28879310 0.71120680) 14) hdi.for.year< 0.748 58 16 No (0.72413793 0.27588207) 28) population=822889 44 7 No (0.84090909 0.15990901) * 29) population< 822889 14 5 Yes (0.35714286 0.64285714) * 15) hdi.for.year>-7.48 174 25 Yes (0.1367816 0.85632184) 30) age=5-14 Years,15-24 Years 30 13 Yes (0.43333333 0.56666667) 60) dgh.for.year>-7.48 174 25 Yes (0.13457816 0.85632184) 31) age=25-34 Years,35-54 Years,55-74 Years,75+ Years 144 12 Yes (0.08333333 0.91666667) *
	No No No No No No No No
20]:	Napraviću stablo na osnovu celog data seta a ne samo jedne godine. #install.packages(caret) library(caret) quant3 <- quantile(hdi.df\$suicides.100k.pop, 0.75) hdi.df\$high.rate <- ifelse(hdi.df\$suicides.100k.pop > quant3, "Yes", "No") hdi.df\$high.rate <- factor(hdi.df\$high.rate) hdi.df\$[c("country", "year", "suicides.100k.pop", "country.year")] <- NULL head(hdi.df) Loading required package: lattice
	A data.frame: 6 × 9 sex age suicides.no population hdi.for.year gdp.for.year fctb cfctb cf
	tree3 <-rpart(high.rate , train.data3, method = "class") print(tree2) rpart.plot(tree3) node), split, n, loss, yval, (yprob)
22]:	#S obzirom da je stablo veliko te se plot ne vidi dobro, kod ispod pravi čitljivu sliku. #pngt "FinalClassTree1.png", width=1280, height=960)
23]:	<pre>#rpart.plot(tree3) #dev.off() tree3.pred <- predict(tree3, test.data, type = "class") tree3.cm <- table(true = test.data\$high.rate, predicted = tree3.pred) tree3.cm predicted true No Yes No 1191 63 Yes 87 331 compute.eval.metrics <- function(cmatrix) { TP <- cmatrix[2,2] TN <- cmatrix[1,1] FP <- cmatrix[1,2]</pre>
	Na osnovu ovih mera možemo zaključiti da ovaj model nije dovoljno precizan. Na osnovu Recall mere (339/339+79) vidimo da je model čak 79 pozitivnih vrednosti prediktovao kao negativne ili približno 19%. Druga mera, Precision (339/339+33) nam govori da je model 33 negativne vrednosti prediktovao kao pozitivne ili približno 9%. Zaključak je da je model sklon da realizovane poziti vrednosti lošije predviđa. U kontekstu ovih podataka u približno 19% slučajeva model je realizovanu visoku stopu suicida evaluirao kao nisku. Razlog bi bili sami podaci. Naime varijable preko kojih želimo da prediktujemo neku drugu varijablu moraju da dele zajednički varijabilitet, odnosno da preko njih možemo da objasnimo varijablu vrednosti želimo da predviđamo. U ovom slučaju, kao odgovor na 5. pitanje (od čega zavisi stopa suicida?) smo pokazali da stopa suicida ne zavisi od GDP-a, dok sa HDI-em postoji značajna korelacija iako je ona ipak slaba. Ukoliko pogledamo grafik stabla možemo videti da ono koristi za odlučivanje HDI i GDP (iako korelacije nema). Ipak, koristi ih za odlučivanje samo po jednom. Razlog zašto najviše koristi varijal "suicides.no" i "population" je logičan s obzirom da smo "sucides.100k.pop" izračunali preko prethodne dve varijable. Upravo ova činjenica se i odražava na preciznost našeg modela. Da bi povećali preciznost modela (pri tom i odgovorili na 5. pitanje) morali bi da imamo neke dodatne varijable koje će bliže i bol objašnjavati stopu suicida u državama.
2	objašnjavati stopu suicida u državama. Zanimljivo je primetiti da možemo intuitivno razumeti kako stablo odlučuje (koje varijable koristi) preko prethodnih pet pitanja tj. odgovora na njih (pokazano je da je stopa suicida daleko viša kod muškaraca, s toga stablo i kreće sa pitanjem o polu, gde slučajeve stope sucida za ženski pol uopšte i ne razmatra).